

ChemAI: Predict the Cure

Предсказание IC50, CC50, SI по молекулярным дескрипторам.

Public Kaggle score: 279.50 RMSE

ДПО Команда Хакатон-Пересдача: Сергей Петров, Христина Анакиева, Дарья Меньшикова, Олег Николашин, Кирилл Лукашов, Кирилл Дублин

Задача и метрика







- **Соревнование:** <https://www.kaggle.com/competitions/chem-ai-predict-the-cure/overview>
- Необходимо предсказать три показателя для каждого химического соединения:
 - IC50 (mM) — концентрация, при которой вещество подавляет 50% активности вируса
 - CC50 (mM) — концентрация, при которой вещество токсично для 50% клеток
 - SI (Selectivity Index) — индекс селективности

Метрика — средний RMSE по IC50, CC50, SI;

Данные: 750 train, 250 test, числовые молекулярные признаки. Есть пропуски (заполняются медианой в пайплайне)

Анализ таргетов

- Исследовательский анализ данных показал, что целевые переменные имеют выраженную асимметрию и длинные правые хвосты.
- Это важно, потому что RMSE сильно штрафует большие ошибки на крупных значениях.
- IC50 и CC50 имеют выбросы, SI особенно нестабилен из-за редких очень больших значений, поэтому использовались $\log_{10}$ -преобразования таргетов



Проверенные гипотезы

Подход	Результат
Дополнительный feature engineering	Не улучшил CV
$\log_{1p}(\text{target})$	Сделал обучение устойчивее
Отдельные модели по таргетам	Лучше, чем единая логика для всех
Seed-ансамбль	Снизил дисперсию предсказаний
QSAR-SVR как независимая модель	Хуже как независимая модель, но улучшила результат ансамбля при бленде 50%+50%

Feature engineering не был включён в финальную модель, потому что новые признаки оказались коррелированы с уже существующими дескрипторами и ухудшили модель

Сравнение моделей

На базовом этапе сравнивались:

- ExtraTreesRegressor
- RandomForestRegressor
- HistGradientBoostingRegressor

Лучший общий baseline: ExtraTrees: 542.9 (OOF mean-RMSE), результат на Kaggle порядка 313

Разные таргеты лучше предсказывались разными моделями, поэтому финальное решение стало таргет-специфичным. По данным таблицы для SI лучшей моделью оказался градиентный бустинг, но в финальном пайплайне устойчивее оказался случайный лес, поэтому использован был именно он

model	IC50_RMSE	CC50_RMSE	SI_RMSE
ExtraTrees	357.8	491.7	779.2
RandomForest	355.7	516.9	779.6
HistGradientBoosting	366.0	510.4	778.3

Финальный пайплайн

Модель 1: таргет-специфичный ансамбль деревьев (submission_1.csv)

- SimpleImputer — заполнение пропусков медианой
- VarianceThreshold — удаление константных признаков
- SelectKBest — отбор признаков для части моделей
- IC50: RandomForest
- CC50: ExtraTrees
- SI: RandomForest
- Усреднение по нескольким random seed

Для IC50 и CC50:

- смесь log-модели и raw-модели (log-модель устойчивее на основной массе объектов, raw-модель лучше учитывает большие значения)

Модель 2: независимая QSAR-SVR (submission_2.csv)

- SimpleImputer - StandardScaler - SelectKBest - SVR
- обучение отдельно для IC50, CC50 и SI на $\log_{10}(\text{target})$

Финальная модель:

результат модели 1 * 0.5 + результат модели 2 * 0.5 (submission.csv)

Проверка результатов на Kaggle

Проверка результатов на Kaggle:

- Модель 1 (ансамбль деревьев) - 293.8 RMSE
- Модель 2 (QSAR-SVR) - 308.12 RMSE
- Финальная модель (бленд моделей 1 и 2 50%/50%) - 279.50 RMSE

Лучший результат получен после:

- таргет-специфичного ансамбля деревьев;
- отдельной модели для SI;
- log/raw-компонент для IC50 и CC50;
- независимой QSAR-SVR модели;
- простого усреднения моделей 1 и 2 50/50.

ChemAI: Predict the Cure

Find the most effective combination of parameters for drug development



[Overview](#) [Data](#) [Code](#) [Models](#) [Discussion](#) [Leaderboard](#) [Rules](#) [Team](#) [Submissions](#)

Leaderboard

[Raw Data](#)

[Refresh](#)

YOUR RECENT SUBMISSION



submission.csv

Submitted by ДПО Команда Хакатон-Пересдача · Submitted a minute ago

Score: 279.50212

[Jump to your leaderboard position](#)